

İNÖNÜ ÜNİVERSİTESİ

Mühendislik Fakültesi
Yazılım Mühendisliği Bölümü

VERİ MADENCİLİĞİ

Dönem Projesi

Spotify Veri Seti Üzerinde Müzik Popülerliği Tahmini İçin Çoklu Makine Öğrenmesi Yaklaşımlarının Değerlendirilmesi

Hazırlayan:

Zehra Çiçek

Öğrenci No:

02220224057

Tarih:

29.12.2025

İÇİNDEKİLER

1. Özet

2. Giriş

- 2.1. Problem Ne?
- 2.2. Bu Problemi Çözmek İçin Neler Yapılmalı?
- 2.3. Bu Çalışmada Ne Yapıldı?

3. Yöntem

- 3.1. Kullanılan Algoritmaların Açıklaması ve Literatür İncelemesi
 - 3.1.1. Malatya Centrality (MC)
 - 3.1.2. K-Means Kümeleme Algoritması
 - 3.1.3. K-Nearest Neighbors (KNN)
 - 3.1.4. Random Forest
 - 3.1.5. Naive Bayes
- 3.2. Veri Seti ve Ön İşleme Adımları
- 3.3. Deneysel Tasarım
- 3.4. Çalışmanın Sözde Kodu (Pseudocode)
- 3.5. Akış Şeması

4. Deneysel Sonuçlar

- 4.1. Malatya Centrality Analizi
- 4.2. Malatya Centrality Skoru En Yüksek 5 Düğüm ve Bu Dğümlerin Diğer Algoritmalarındaki Performans Karşılaştırması
- 4.3. Artan Düğüm Sayısında Algoritmaların Ortalama Skor Performansları
- 4.4. Farklı Veri Büyüklüklerinde Şarkı Öneri Çıktılarının Karşılaştırılması
 - 4.4.1. Küçük Ölçekli Örneklemeler (10-50)
 - 4.4.2. Orta Ölçekli Örneklemeler (100-500)
 - 4.4.3. Büyük Ölçekli Örneklemeler (1000-5000)

5. Sonuçlar ve Tartışma

6. Proje Kodları ve Uygulama Detayları

- 6.1. Veri Yükleme ve Ön İşleme Kodu
- 6.2. Algoritmaların Uygulanması
 - 6.2.1. Malatya Centrality Algoritması
 - 6.2.2. K-Means Algoritması
 - 6.2.3. K-Nearest Neighbors (KNN)
 - 6.2.4. Random Forest
 - 6.2.5. Naive Bayes
- 6.3. Deneysel Sürecin Yürütülmesi
- 6.4. Ana Çalıştırma Akışı ve Sonuçların Üretilmesi
- 6.5. Kodların Akademik Katkısı

7. Ekler

1.Özet

Bu çalışma, Spotify veri seti kullanılarak şarkıların popülerlik düzeylerini tahmin etmeyi ve farklı makine öğrenmesi algoritmalarının performansını karşılaştırmayı amaçlamaktadır. Spotify, her parça için tempo, enerji, dans edilebilirlik, valans, ses yüksekliği gibi çok boyutlu akustik özellikler sunmaktadır. Bu özelliklerin popülerlik ile ilişkisi literatürde sıkça incelenmiş olsa da, mevcut çalışmalar çoğunlukla belirli algoritmalarla sınırlı kalmıştır. Bu proje, hem sınıflandırma hem de kümeleme algoritmalarını kapsayan kapsamlı bir yaklaşım benimseyerek literatürdeki boşluğu doldurmayı hedeflemektedir.

Çalışmada Malatya Centralıty, K-Means, KNN, Random Forest ve Naive Bayes algoritmaları uygulanmış, her biri farklı veri miktarlarında (10, 20, 50, 100, 200, 500, 1000, 2000, 5000 kayıt) test edilmiştir. Veri miktarı arttıkça algoritmaların doğruluk, işlem süresi ve kararlılık performanslarındaki değişimler detaylı şekilde incelenmiştir. K-Means modeli doğal küme yapısını en iyi ortaya koyarken; Random Forest, sınıflandırmada en yüksek başarıyı elde etmiştir. Naive Bayes düşük veri miktarlarında kararlı sonuçlar üretmiş, KNN ise veri arttıkça daha istikrarlı hale gelmiştir.

Elde edilen sonuçlar, Spotify'nın zengin ses özelliklerinin makine öğrenmesi modelleri için güçlü bir temel sunduğunu ve doğru yöntem seçildiğinde popülerliğin yüksek doğrulukla tahmin edilebileceğini göstermektedir. Çalışma, müzik analitiği ve öneri sistemlerine yönelik gelecekteki araştırmalar için önemli bir referans oluşturmaktadır.

2. Giriş

2.1. Problem Ne?

Milyonlarca kullanıcıya sahip dijital müzik platformlarında şarkıların popülerliğini etkileyen faktörleri anlamak hem akademik hem de sektörel açıdan kritik bir araştırma alanıdır. Ancak Spotify verilerinde popülerlik, çok sayıda akustik ve davranışsal özellikten etkilenen karmaşık bir yapıya sahiptir.

2.2. Bu Problemi Çözmek İçin Neler Yapılmalı?

Bu problemi çözebilmek için öncelikle Spotify'nın sunduğu çok boyutlu akustik özelliklerin ayrıntılı biçimde analiz edilmesi gerekmektedir. Tempo, enerji, dans edilebilirlik, valans ve akustiklik gibi değişkenlerin popülerlik ile ilişkisi doğru şekilde ortaya konulmadan etkili bir tahmin modeli geliştirmek mümkün değildir. Bunun yanı sıra, veri madenciliği modellerinin farklı veri büyüklüklerinde nasıl davrandığının incelenmesi büyük önem taşımaktadır; zira algoritmaların performansı özellikle 10 ile 5000 kayıt arasında ciddi değişiklik gösterebilmektedir. Bu nedenle sınıflandırma, regresyon ve kümeleme yaklaşımlarının her biri değerlendirilerek, veri setine en uygun yöntemin belirlenmesi hedeflenmiştir. Sonuç olarak, tüm algoritmaların doğruluk, işlem süresi ve kararlılık açısından karşılaştırılması, popülerliği en doğru tahmin eden modelin tespit edilmesine olanak sağlayacak ve bu problem için en etkili çözüm yolunu ortaya çıkaracaktır.

2.3. Bu Çalışmada Ne Yapıldı?

Bu projede beş farklı algoritma (Malatya Centrality, K-Means, KNN, Random Forest, Naive Bayes) kullanılarak Spotify verilerindeki popülerlik tahmin edilmeye çalışılmıştır. Veriler farklı miktarlara bölünerek her algoritma hem doğruluk hem hız hem de kararlılık açısından test edilmiştir. Sonuçlar tablo ve grafiklerle sunulmuş, algoritmaların avantajları ve dezavantajları tartışılmıştır.

3. Yöntem

Bu bölümde çalışmada kullanılan yöntemsel yaklaşım ayrıntılı biçimde sunulmaktadır. Yöntem; veri setinin hazırlanması, ön işleme süreçleri, kullanılan algoritmaların bilimsel temelleri, deneysel tasarım, sözde kod ve akış şeması olmak üzere beş temel unsurdan oluşmaktadır. Amaç, Spotify şarkı özelliklerinden popülerlik tahmini yapmak için uygulanan makine öğrenmesi sürecinin, literatürle uyumlu ve tekrarlanabilir bir biçimde ortaya konulmasıdır.

3.1 Kullanılan Algoritmaların Açıklaması ve Literatür İncelemesi

Bu çalışmada beş farklı yöntem uygulanmıştır: Malatya Centrality, K-Means, K-Nearest Neighbors (KNN), Random Forest ve Naive Bayes. Bu bölümde algoritmaların teknik yapıları ve literatürde Spotify verileri üzerindeki kullanımları özetlenmiştir.

3.1.1 Malatya Centrality (MC)

$$\psi(v_i) = \sum_{v_j \in N(v_i)} \frac{d(v_i)}{d(v_j)}$$

Malatya Centrality (MC), veri noktaları arasındaki ilişkileri grafik teorisine dayalı olarak değerlendiren merkezilik temelli bir ölçümdür. Bu çalışmada Spotify veri setindeki her bir şarkı grafik üzerinde birer düğüm olarak modellenmiş, şarkılar arasındaki akustik benzerlik düzeyleri ise kenar ağırlıkları üzerinden temsil edilmiştir. En yüksek MC değerine sahip şarkılar, ağ yapısı içerisinde diğer şarkılarla daha güçlü ve yoğun ilişkiler kuran, dolayısıyla daha merkezi konumda bulunan örnekler olarak yorumlanmıştır.

Literatürde MC doğrudan bu isimle yaygın biçimde kullanılsa da, benzerlik temelli ağ yapıları üzerinden merkezi örneklerin belirlenmesi popülerlik tahmini ve öneri sistemleri açısından önemli bir yaklaşımdır. Saragih (2023) ve ABACademies (2025), veri seti içindeki temsil gücü yüksek örneklerin model performansını doğrudan etkilediğini göstermiştir. Bu nedenle MC, çalışmada şarkıların veri kümesi içerisindeki göreceli konumlarını analiz etmek ve merkezi şarkıların diğer algoritmalarla olan ilişkisini incelemek amacıyla tamamlayıcı bir analiz aracı olarak kullanılmıştır.


3.1.2 K-Means Kümeleme Algoritması

$$s = \frac{b - a}{\max(a, b)}$$

K-Means, veri noktalarını benzerliklerine göre K adet kümeye ayıran sezgisel bir kümeleme yöntemidir. Spotify'ın akustik özellikleri doğal kümelenme eğilimleri gösterdiğinden, K-Means bu veri türünde başarılı sonuçlar sağlar.

Middlebrook & Sheik (2019), hit şarkıların davranışlarını analiz etmek için K-Means'i kullanmış ve yöntemin Spotify verisinde tutarlı kümeler oluşturduğunu göstermiştir. Janardhan & Plavchan (2023) ise farklı kümeleme algoritmalarını karşılaştırarak K-Means'in Spotify verisinde en kararlı ve anlamlı kümeleri verdiğini raporlamıştır.

Bu çalışmada, K-Means şarkıların akustik açıdan benzer gruplara ayrılıp ayrılmadığını incelemek amacıyla uygulanmıştır.



Bu görselde, 5000 gözlemden oluşan Spotify veri seti K-Means algoritması ile kümelenebilir ve PCA yöntemi kullanılarak iki boyutlu uzayda görselleştirilmiştir. Sarı ve mor noktalar, benzer akustik özelliklere sahip şarkı gruplarını temsil etmektedir. K-Means algoritması, tempo, enerji, dans edilebilirlik ve valans gibi çok boyutlu ses özelliklerini dikkate alarak şarkıları doğal segmentlere ayırmıştır. Kümeler arasındaki belirgin görsel ayrım, Spotify veri setinde akustik açıdan farklı karakterlere sahip şarkı gruplarının bulunduğunu ve bu yapının K-Means tarafından başarılı şekilde yakalandığını ortaya koymaktadır.

3.1.3 K-Nearest Neighbors (KNN)

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

KNN, bir örneğin sınıfının en yakın komşularına bakılarak belirlendiği sezgisel bir sınıflandırma yöntemidir. Normalize edilmiş ve düşük boyutlu veri setlerinde yüksek doğruluk vermesiyle bilinir.

Luo (2018), Spotify tür sınıflandırmasında KNN'nin kararlı sonuçlar verdiğini göstermiştir. Mountzouris (2025), KNN'nin dengesiz veri setlerinde parametre ayarına duyarlı olduğunu ancak doğru ayarlandığında rekabetçi performans sunduğunu belirtmiştir.

Bu projede KNN, popülerliği düşük-orta-yüksek olmak üzere üç kategoriye ayırmak için kullanılmıştır.


3.1.4 Random Forest

$$\Delta Gini = Gini(parent) - \sum \frac{N_k}{N} Gini(k) \quad Entropy(S) = - \sum_{i=1}^C p_i \log_2(p_i) \quad \hat{y} = \frac{1}{n} \sum_{i=1}^n h_i(x)$$

Random Forest, birçok karar ağacından oluşan güçlü bir topluluk öğrenmesi yöntemidir. Büyük veri setlerinde yüksek doğruluk, genelleme ve aşırı öğrenmeye karşı dayanıklılık sağlamasıyla literatürde yaygın olarak tercih edilir.

Luo (2018), Spotify tür sınıflandırmasında Random Forest'in %89 doğrulukla en iyi sonuç veren model olduğunu belirtmiştir. Saragih (2023) ise regresyon görevlerinde RF'nin karmaşık ilişkileri yakalamada başarılı olduğunu göstermiştir.

Bu çalışmada RF, yüksek doğruluk beklenen temel sınıflandırma modeli olarak seçilmiştir.



Bu görsel, 5000 gözlemlili veri seti üzerinde eğitilen Random Forest modelinin özellik önemlerini göstermektedir. Sonuçlar, şarkı popülerliği tahmininde özellikle ses yüksekliği (loudness), akustiklik ve konuşabilirlik gibi özelliklerin belirleyici olduğunu ortaya koymaktadır.

3.1.5 Naive Bayes

$$P(Y|X) = \frac{P(X|Y) P(Y)}{P(X)}$$

Naive Bayes, Bayes teoremini temel alan ve özelliklerin birbirinden bağımsız olduğunu varsayarak çalışan olasılıksal bir algoritmadır. Küçük veri setlerinde hızlı ve etkili olmasıyla bilinir.

Maheshwari et al. (2023), Spotify verisi üzerinde NB'yi referans model olarak test etmiş ve hız avantajı nedeniyle değerli bir karşılaştırma aracı olduğunu raporlamıştır.

Bu projede NB tüm veri boyutlarında karşılaştırma amacıyla temel model olarak kullanılmıştır.

3.2 Veri Seti ve Ön İşleme Adımları

Bu çalışmada kullanılan veri seti, Spotify API aracılığıyla elde edilmiş olup şarkılara ait tempo, enerji, dans edilebilirlik, valans, akustiklik ve konuşabilirlik gibi çok boyutlu akustik özellikleri içermektedir. Ham verinin makine öğrenmesi algoritmaları için uygun hâle getirilmesi amacıyla kapsamlı bir ön işleme süreci uygulanmıştır. Bu süreçte öncelikle veri setinde yer alan eksik değerler incelenmiş ve model performansını olumsuz etkilememesi adına veri setinden temizlenmiştir. Ardından, istatistiksel olarak normal dağılımdan sapma gösteren aykırı değerler tespit edilerek veri setinden ayıklanmıştır. Özellikler arasındaki ölçek farklılıklarını ortadan kaldırmak ve algoritmaların daha dengeli ve karşılaştırılabilir biçimde öğrenmesini sağlamak amacıyla tüm sayısal değişkenlere Min-Max normalizasyonu uygulanmıştır. Son olarak, sürekli bir değişken olan popülerlik değeri, sınıflandırma problemlerine daha ayrıntılı ve ayırt edici bir yapı kazandırmak amacıyla kategorik hâle dönüştürülmüştür. Bu kapsamda popülerlik değeri; 0–20 aralığı “En Düşük”, 20–40 aralığı “Düşük”, 40–60 aralığı “Orta”, 60–80 aralığı “Yüksek” ve 80–100 aralığı “En Yüksek” olmak üzere beş farklı sınıf altında tanımlanmıştır. Bu beş sınıflı yapı sayesinde, şarkıların popülerlik düzeyleri daha hassas biçimde temsil edilmiş ve özellikle orta ile yüksek popülerlik seviyeleri arasındaki farkların algoritmalar tarafından daha net biçimde öğrenilmesi sağlanmıştır. Uygulanan bu ön işleme adımları, müzik veri madenciliği alanında yaygın olarak kabul gören yöntemlerle uyumlu olup literatürde önerilen standartlara dayanmaktadır (Guyon & Elisseeff, 2003).

3.3 Deneysel Tasarım

Deneysel çalışmada, kullanılan algoritmaların farklı veri büyüklüklerindeki performanslarını gözlemleyebilmek amacıyla çoklu örneklem temelli bir tasarım benimsenmiştir. Algoritmalar

sırasıyla 10, 20, 50, 100, 200, 500, 1000, 2000 ve 5000 kayıt içeren veri alt kümeleri üzerinde test edilmiştir. Her bir veri boyutu için deneysel süreç aynı şekilde yürütülmüş ve sonuçların karşılaştırılabilir olması sağlanmıştır. Veri alt kümeleri her deneyde rastgele örneklenmiş, ardından veri seti %80 eğitim ve %20 test olacak şekilde ayrılmıştır. Rastlantısallığın etkisini azaltmak ve daha güvenilir sonuçlar elde etmek amacıyla her algoritma her veri boyutu için 10 kez çalıştırılmıştır. Deneyler sonucunda doğruluk, işlem süresi ve kararlılık (standart sapma) metrikleri hesaplanmış; kümeleme yöntemi olan K-Means için ek olarak kümeler arası ayrışma ölçütleri değerlendirilmiştir. Bu deneysel yaklaşım, farklı veri büyüklüklerinde algoritma davranışlarını analiz etmeyi amaçlayan ve literatürde önerilen çoklu örneklem metodolojileriyle uyumlu bir yapı sunmaktadır (Saragih, 2023; Middlebrook & Sheik, 2019).

3.4 Çalışmanın Sözde Kodu (Pseudocode)

INPUT: Spotify dataset D
SIZES = [10, 20, 50, 100, 200, 500, 1000, 2000, 5000]
ALGORITHMS = {MC, KMEANS, KNN, RF, NB}

1. Veri Hazırlama

CLEAN(D)

NORMALIZE(D)

ENCODE_POPULARITY(D)

2. Deneysel Süreç

FOR each size s in SIZES:

 D_s = RANDOM_SAMPLE(D, s)

 Train_s, Test_s = TRAIN_TEST_SPLIT(D_s, 0.8)

 FOR each algorithm A in ALGORITHMS:

 FOR i = 1 to 10:

 model_i = TRAIN(A, Train_s)


 pred_i = PREDICT(model_i, Test_s)

 metrics[i] = EVALUATE(pred_i, Test_s)

 RESULTS[s][A] = MEAN(metrics)

RETURN RESULTS


3.5 Akış Şeması



4.Deneysel Sonuçlar

Bu bölümde beş farklı algoritmanın — Malatya Centrality, K-Means, KNN, Random Forest ve Naive Bayes — farklı veri büyüklüklerinde (10, 20, 50, 100, 200, 500, 1000, 2000 ve 5000 gözlem) gösterdikleri performans karşılaştırmalı olarak sunulmaktadır. Amaç, veri miktarı arttıkça algoritmaların doğruluk, kararlılık, işlem süresi ve küme ayrışma davranışlarının nasıl değiştiğini gözlemlemektir.

Deneylerde tüm veri alt kümeleri %80 eğitim – %20 test şeklinde ayrılmış, her model 10 tekrar çalıştırılarak ortalama değerler kullanılmıştır. Bu yaklaşım, sonuçların rastlantısallıktan arındırılmasını sağlamıştır.



Yukarıdaki şekil , beş farklı algoritmanın farklı veri büyüklükleri üzerindeki davranışlarını bütüncül olarak göstermektedir. Sınıflandırma başarıları incelendiğinde Random Forest, hem doğruluk hem de F1 skoru açısından en istikrarlı ve yüksek performanslı model olarak öne çıkmaktadır. Özellikle veri miktarı arttıkça RF'nin performans eğrisinin daha az dalgalandığı ve büyük veri setlerinde kararlı sonuçlar ürettiği görülmektedir. Buna karşın KNN düşük veri miktarlarında ciddi performans kayıpları yaşamış ancak veri büyüdükçe daha dengeli bir yapıya kavuşmuştur. Naive Bayes ise küçük örneklemelerde nispeten avantajlı görünse de veri karmaşıklıklaştıkça sınıflandırma kabiliyetini kaybetmiştir.


İşlem maliyetleri açısından bakıldığında, Naive Bayes en hızlı algoritma olarak açık bir üstünlük sergilemektedir, KNN de düşük maliyeti korurken, Random Forest artan ağaç yapısı nedeniyle en yüksek çalışma süresine ulaşmıştır. Bu sonuç, RF'nin yüksek performansının ek hesaplama maliyeti ile dengelendiğini göstermektedir.

Kümeleme sonuçlarında K-Means'in Silhouette skorlarının özellikle düşük veri boyutlarında tepe yaptığı, daha sonra azalma eğilimine girdiği görülmektedir. Ancak Davies–Bouldin indeksinin veri miktarı arttıkça sürekli iyileşmesi, büyük veri setlerinde doğal kümelenme davranışının güçlendiğine işaret etmektedir.

Genel olarak grafik, yüksek doğruluk isteyen senaryolarda Random Forest'ın; hız önceliği olan senaryolarda Naive Bayes'in; büyük verili doğal segmentasyon gerektiren durumlarda ise K-Means'in uygun bir tercih olacağına işaret etmektedir. Bu açıdan bakıldığında, model seçiminin hedef metriklerle göre değişmesi gerektiği net biçimde ortaya çıkmaktadır.

4.1.Malatya Centrality Analizi

En Yüksek Malatya Centrality Skoruna Sahip 50 Düğümün Graf Yapısı



Yukarıdaki görselde Malatya Centrality metriğine göre en yüksek merkezilik değerine sahip 50 düğümün korelasyon grafini göstermektedir. Yoğun bağlantı bölgeleri, özellikler arası güçlü ilişki kümelerini temsil eder. Bu yapı, Spotify akustik değişkenlerinin popülerlik tahminindeki etkisinin ağ merkeziliği üzerinden incelenmesine olanak sunmaktadır.

Aşağıdaki görselde 5000 gözleme sahip veri seti için Malatya Centrality skorlarının PCA ile iki boyutlu uzayda gösterimini sunmaktadır. Yoğunlaşan nokta kümeleri, değişkenlerin belirli




bölgelerde toplandığını ve korelasyon yapısının doğal segmentlere ayrıldığını göstermektedir.


Renk skalası MC skorunu temsil etmektedir; yüksek skorlar (yeşil ve sarı tonları), belirli yoğunluk odaklarında toplanmış, bu durum akustik özelliklerin popülerlik etkisinin belirli eksenlerde yoğunlaştığını işaret etmektedir.

Bu dağılım, yüksek merkeziliğe sahip düğümlerin rastlantısal olmadığını; aksine istatistiksel olarak anlamlı biçimde gruplaştığını ortaya koymaktadır.

Veri Miktarı	Düğüm	Kenar Sayısı	En Yüksek MC	En Yüksek MC'ye Sahip Şarkı	Ortalama MC
10	10	7	3.2000	Walking in a winter	2.4000
20	20	81	3.7000	We found love	3.3703
50	50	645	4.0345	Everything is Sound	3.5964
100	100	3,111	3.9718	Everything is Sound	3.6917
200	200	12,673	4.0214	Give Me Something	3.7426
500	500	84,526	4.0914	Father's day	3.7871
1000	1000	343,63	4.1003	Together As One	3.7834
2000	2000	1,478,619	4.0883	Together As One	3.8012
5000	5000	7,766,082	4.3868	Together As One	3.7651



4.2 Malatya Centrality Skoru En Yüksek 5 Düğüm ve Bu Düzgümlerin Diğer Algoritmalarındaki Performans Karşılaştırması




Yukarıdaki şekil , Malatya Centrality metriğine göre en yüksek merkezilik skoruna sahip ilk beş düğümün (sol grafik) ve aynı düğümlerin diğer algoritmalar (K-Means, KNN, Naive Bayes, Random Forest) elde ettikleri skorların (sağ grafik) karşılaştırmasını göstermektedir. Sol grafikte görülen ID: 6666, 1844, 5448, 7681 ve 4715, ağ yapısında diğer düğümlerle yoğun bağlantı kurduğu için en merkezi beş bileşeni temsil etmektedir. Bu yüksek merkezilik değerleri, söz konusu düğümlerin veri kümesi içindeki etkileşim yoğunluğunu ve olası bilgi akışını belirgin biçimde artırmaktadır.

Sağ taraftaki grafik ise bu beş düğümün sınıflandırma ve kümeleme algoritmalarındaki çıktıları karşılaştırmaktadır. Random Forest tüm örneklerde en yüksek skoru üretmiş,

Naive Bayes ise genel olarak ikinci sırayı korumuştur. K-Means ve KNN, bu merkezi düğümlerde daha düşük skorlar sergileyerek merkeziliği yakalamakta sınırlı kalmıştır. Bu bütüncül değerlendirme, yüksek MC skorunun tahmine dayalı modellerde de avantaj yarattığını, özellikle Random Forest gibi ensemble yaklaşımlarının merkeziliği daha iyi değerlendirdiğini göstermektedir. Bu durum, merkezilik ölçümlerinin veri madenciliği modellerine entegre edilmesinin özellik seçimi açısından stratejik bir yarar sağlayabileceğini ortaya koymaktadır.

4.3 Artan Düğüm Sayısında Algoritmaların Ortalama Skor Performansları



Yukarıdaki şekil, farklı k değerleri için algoritmaların ortalama skor performansını göstermektedir. En belirgin artış eğrisi Malatya Centrality’de gözlenmiş; $k \geq 200$ seviyesinden itibaren MC’nin diğer tüm algoritmaların üstüne çıktığı ve artan düğüm sayısı ile birlikte ekspanansiyel bir yükseliş yakaladığı görülmüştür.

Buna karşılık K-Means, KNN, Naive Bayes ve Random Forest modelleri k arttıkça neredeyse yatay bir davranış sergilemiş, ortalama performansları 0.8 – 1.2 bandında kalmıştır. Bu sonuç, klasik sınıflandırma ve kümeleme yaklaşımlarının yüksek düğüm yoğunluğundan MC kadar faydalanamadığını göstermektedir.

Bu grafik genel olarak MC’nin temsil gücünün ve öz nitelik ayrıştırma kapasitesinin, veri hacmi büyüdükçe daha belirgin hale geldiğini, dolayısıyla yüksek boyutlu ilişkisel veri yapılarında MC’nin avantaj sağlayabileceğini ortaya koymaktadır.

4.4 Farklı Veri Büyüklüklerinde Şarkı Öneri Çıktılarının Karşılaştırılması

Bu bölümde, farklı veri büyüklüklerinde (10 → 5000 gözlem) algoritmaların önerdiği en yüksek skorlu parçalar tablolandırılmıştır. Amaç, örneklem genişledikçe algoritmaların yaklaşımlarının nasıl değiştiğini gözlemlemek ve hangi yöntemlerin tutarlı öneriler sunduğunu belirlemektir.

4.4.1 Küçük Örneklem (10 – 50)

Base 10 Düşüm - Karşılaştırma Tablosu

Sıra	Malatya Centrality	K-Means	KNN	Random Forest	Naive Bayes
1	Walking in a Winter Skor: 119.6993	What They Say Skor: 0.6973	Say Anything Skor: 0.9543	Walking in a Winter Skor: 38.4283	Dancing Shoes Skor: 0.9958
2	Dancing Shoes Skor: 119.1190	Living in the Moment Skor: 0.5222	Dancing Shoes Skor: 0.9504	Dancing Shoes Skor: 38.4276	Say Anything Skor: 0.9874
3	I Shall Be Released Skor: 117.2283	Money (That's What I Skor: 0.4761	Money (That's What I Skor: 0.9503	Say Anything Skor: 38.0234	Teenage Dream Skor: 0.9755
4	Say Anything Skor: 115.1651	I Shall Be Released Skor: 0.4296	Living in the Moment Skor: 0.9477	I Shall Be Released Skor: 38.0093	Walking in a Winter Skor: 0.9741
5	Teenage Dream Skor: 110.0669	Holding On and Letti Skor: 0.3948	Teenage Dream Skor: 0.9444	Teenage Dream Skor: 37.2194	Fix You Skor: 0.9676
6	Holding On and Letti Skor: 91.0848	Walking in a Winter Skor: 0.3673	Walking in a Winter Skor: 0.9424	Holding On and Letti Skor: 34.4139	Holding On and Letti Skor: 0.9589
7	Fix You Skor: 79.8068	Fix You Skor: 0.3554	Fix You Skor: 0.9352	Fix You Skor: 32.4258	I Shall Be Released Skor: 0.9478
8	Money (That's What I Skor: 69.6451	Teenage Dream Skor: 0.3452	I Shall Be Released Skor: 0.9260	Money (That's What I Skor: 29.2225	Money (That's What I Skor: 0.9239
9	Living in the Moment Skor: 55.6514	Say Anything Skor: 0.3183	Holding On and Letti Skor: 0.9153	Living in the Moment Skor: 26.0217	Living in the Moment Skor: 0.9004
10	What They Say Skor: 36.3521	Dancing Shoes Skor: 0.2865	What They Say Skor: 0.8929	What They Say Skor: 20.8141	What They Say Skor: 0.8088

Bu tabloda, yalnızca 10 düşüm içeren küçük örneklem üzerinde algoritmaların önerdiği en yüksek skorlu şarkılar karşılaştırılmıştır. Küçük veri boyutunda algoritmalar arasında belirgin farklılıklar gözlemlenmekte olup, önerilerin büyük ölçüde algoritmanın yapısına bağlı olarak değiştiği görülmektedir. Özellikle Malatya Centrality ve KNN yaklaşımlarının daha çeşitli sonuçlar üretmesi, küçük örneklemelerde merkezilik ve benzerlik temelli yöntemlerin daha duyarlı davrandığını göstermektedir.

Base 20 Düşüm - Karşılaştırma Tablosu

Sıra	Malatya Centrality	K-Means	KNN	Random Forest	Naive Bayes
1	We Found Love Skor: 250.5638	Better with You Skor: 0.5489	Kingdom Come Skor: 0.9738	We Found Love Skor: 77.6087	The Hearse Song Skor: 0.9938
2	The One That Got Awa Skor: 245.2587	Once Upon Another Ti Skor: 0.5255	Payphone Skor: 0.9731	The One That Got Awa Skor: 77.2168	The One That Got Awa Skor: 0.9922
3	Rolling In The Deep Skor: 240.2635	The Woman I Love Skor: 0.4343	The Woman I Love Skor: 0.9726	Rolling In The Deep Skor: 76.4116	We Found Love Skor: 0.9876
4	A Thousand Miles Skor: 235.3420	A Thousand Miles Skor: 0.4012	Without You Skor: 0.9717	The Hearse Song Skor: 75.2172	Here Without You Skor: 0.9829
5	The Hearse Song Skor: 225.8922	Transvestities Can B Skor: 0.3900	What Makes You Beaut Skor: 0.9711	A Thousand Miles Skor: 75.2041	Rolling In The Deep Skor: 0.9791
6	Back for Good Skor: 224.8752	Back for Good Skor: 0.3847	We Found Love Skor: 0.9641	Back for Good Skor: 74.4084	Glad You Came Skor: 0.9780
7	Here Without You Skor: 212.2538	Payphone Skor: 0.3833	The One That Got Awa Skor: 0.9621	Here Without You Skor: 71.6176	Without You Skor: 0.9741
8	Glad You Came Skor: 202.9263	Superman Skor: 0.3701	The Hearse Song Skor: 0.9603	Somebody That I Used Skor: 70.4094	Somebody That I Used Skor: 0.9732
9	Transvestities Can B Skor: 201.6319	Wherever You Will Go Skor: 0.3671	Glad You Came Skor: 0.9595	Glad You Came Skor: 70.4081	Back for Good Skor: 0.9657
10	Somebody That I Used Skor: 194.4242	I Want It That Way Skor: 0.3633	Superman Skor: 0.9580	Transvestities Can B Skor: 69.6053	I Want It That Way Skor: 0.9642

Veri miktarının artmasıyla bazı algoritmaların önerileri kısmen örtüşmeye başlamış, model davranışları daha dengeli hâle gelmiştir.

Base 50 Düğüm - Karşılaştırma Tablosu

Sıra	Malatya Centrality	K-Means	KNN	Random Forest	Naive Bayes
1	Everything Is Sound Skor: 611.8869	Fuck You Skor: 0.7600	kanashii yume o mita Skor: 0.9863	Everything Is Sound Skor: 191.2012	Firework Skor: 0.9986
2	For the First Time Skor: 610.4276	The Freedom Song Skor: 0.5873	St Louis Elegy Skor: 0.9838	For the First Time Skor: 191.1958	Best of You Skor: 0.9976
3	Firework Skor: 589.4630	Ima Killer Skor: 0.5788	Airplanes Skor: 0.9817	Firework Skor: 188.8118	Everything Is Sound Skor: 0.9908
4	In My Bones Skor: 588.4965	Stuck On You Skor: 0.5437	Black Dog Skor: 0.9799	In My Bones Skor: 188.3980	Breakeven (Falling t Skor: 0.9903
5	Just a Kiss Skor: 588.2728	The Gravedigger's So Skor: 0.5352	Bleeding Muddy Water Skor: 0.9793	Just a Kiss Skor: 187.9973	Someday (Electric) Skor: 0.9864
6	Breaking the Rules Skor: 584.0558	Ode to Sad Disco Skor: 0.5220	Simple Things Skor: 0.9786	Breaking the Rules Skor: 186.0039	Nothin' on You / My Skor: 0.9859
7	Someday (Electric) Skor: 553.7161	hikari no furusato Skor: 0.5035	hikari no furusato Skor: 0.9781	Someday (Electric) Skor: 184.0009	For the First Time Skor: 0.9845
8	Best of You Skor: 547.9177	kanashii yume o mita Skor: 0.4820	With Arms Wide Open Skor: 0.9779	Best of You Skor: 183.6120	Walking in a Winter Skor: 0.9839
9	Breakeven (Falling t Skor: 539.8375	希望のうた Skor: 0.4662	Best of You Skor: 0.9779	Breakeven (Falling t Skor: 182.4049	Will You Be There Skor: 0.9817
10	Still Here Skor: 525.6264	Everybody Knows My N Skor: 0.4458	Faithfully Skor: 0.9768	Winter Wonderland Skor: 177.1960	Sweet As Whole Skor: 0.9811

Veri miktarının artmasıyla algoritmaların önerileri daha dengeli hâle gelmiş, özellikle Random Forest ve Malatya Centrality benzer sonuçlar üretmeye başlamıştır.

4.4.2 Orta Ölçekli Örneklemeler (100 – 500)

Base 100 Düğüm - Karşılaştırma Tablosu

Sıra	Malatya Centrality	K-Means	KNN	Random Forest	Naive Bayes
1	Everything Is Sound Skor: 1242.1023	Dilo Como Yo (Te Est Skor: 0.7540	The Old Guitar Skor: 0.9861	Everything Is Sound Skor: 382.8001	Paradise - Acoustic Skor: 0.9986
2	Hate Song for Brains Skor: 1233.3545	Fuck You Skor: 0.7088	Walking in a Winter Skor: 0.9858	Hate Song for Brains Skor: 381.5857	Hate Song for Brains Skor: 0.9965
3	Beer (Acoustic) Skor: 1212.0468	Not There Yet Skor: 0.7050	I Heard The Bells On Skor: 0.9858	Beer (Acoustic) Skor: 379.5913	Everything Is Sound Skor: 0.9958
4	Just a Kiss Skor: 1207.5206	Tiers monde Skor: 0.6713	Hate & Love Skor: 0.9843	I Was Gonna Marry Yo Skor: 378.7873	Beer (Acoustic) Skor: 0.9953
5	I Was Gonna Marry Yo Skor: 1204.4192	Knock Knock Skor: 0.6513	Bleeding Muddy Water Skor: 0.9819	For the First Time Skor: 377.9954	Mean Skor: 0.9933
6	Shimmer Skor: 1203.9266	Acid Rock Skor: 0.6183	Have Yourself a Merr Skor: 0.9819	Just a Kiss Skor: 377.5963	I Was Gonna Marry Yo Skor: 0.9915
7	For the First Time Skor: 1201.0501	My Weakness Skor: 0.6146	Black Dog Skor: 0.9814	Shimmer Skor: 377.1937	Ghost Skor: 0.9912
8	Don't Speak Skor: 1186.5636	Akula Owu Onyeara Skor: 0.5817	I'll Never Get Over Skor: 0.9814	Don't Speak Skor: 375.9823	Hate & Love Skor: 0.9908
9	Paradise - Acoustic Skor: 1158.9211	Harborview Hospital Skor: 0.5671	Coal War - from Sons Skor: 0.9813	Paradise - Acoustic Skor: 373.6017	Shimmer Skor: 0.9897
10	In My Bones Skor: 1158.5089	Mother's Song Skor: 0.5649	Angels We Have Heard Skor: 0.9813	In My Bones Skor: 371.9972	For the First Time Skor: 0.9890

100 düğüm seviyesinde algoritmalar arasında öneri yakınsaması artmış ve model davranışları daha kararlı bir yapı kazanmıştır.

Base 200 Düşüm - Karşılaştırma Tablosu

Sıra	Malatya Centrality	K-Means	KNN	Random Forest	Naive Bayes
1	Give Me Something Skor: 1228.2131	Hate & Kill Skor: 0.6889	sanbiki no kuma Skor: 0.9864	Almost Honest Skor: 379.9809	See The Conqueror Skor: 0.9993
2	Almost Honest Skor: 1219.9961	Suck on Soil Lounge Skor: 0.6555	Back With Me Skor: 0.9848	My Baby Skor: 379.9783	My Baby Skor: 0.9970
3	Disaster Road Skor: 1216.3433	Run Skor: 0.6532	David Livingstone Skor: 0.9847	Give Me Something Skor: 379.9688	Bring You Home Skor: 0.9950
4	My Baby Skor: 1215.9635	The People I Know Skor: 0.6190	Sabotage Skor: 0.9843	Disaster Road Skor: 379.5679	Bowen Island Skor: 0.9947
5	Leave the Lights On Skor: 1202.6972	watashi no nusubito Skor: 0.6181	kiseki wa itsudemo Skor: 0.9839	See The Conqueror Skor: 378.3835	Dear Sweetheart Skor: 0.9947
6	See The Conqueror Skor: 1200.0482	Deep Dark Basement Skor: 0.6146	This Moment Now Skor: 0.9837	Leave the Lights On Skor: 377.5775	Change My Needs Skor: 0.9944
7	Fortune Teller Skor: 1199.3199	Still Smokin' Skor: 0.6137	Adelina Skor: 0.9836	Give It Time Skor: 377.1699	A Beautiful World Skor: 0.9937
8	Give It Time Skor: 1195.7073	Dipping Things in St Skor: 0.6079	The World as I See I Skor: 0.9835	Everything Skor: 376.3716	Almost Honest Skor: 0.9930
9	Fixin' To Die Blues Skor: 1190.3334	Home Skor: 0.6046	Carolina Skor: 0.9835	Fortune Teller Skor: 375.9678	Kiss Me Skor: 0.9928
10	Everything Skor: 1189.2416	Be the Bigger Man Skor: 0.6042	Give Me Something Skor: 0.9832	Fixin' To Die Blues Skor: 374.7662	Where The Mountain M Skor: 0.9922

Bu seviyede algoritmaların önerileri belirgin biçimde yakınsamış ve model çıktıları daha kararlı hâle gelmiştir.

Base 500 Düşüm - Karşılaştırma Tablosu

Sıra	Malatya Centrality	K-Means	KNN	Random Forest	Naive Bayes
1	Father's Day Skor: 1231.1520	"Sunday Best - Live Skor: 2011.4572	Cargo Cult Skor: 0.9886	Streetlight in the E Skor: 381.1601	Streetlight in the E Skor: 0.9988
2	Burn the House Down Skor: 1230.1687	Juan Loco - Area 52 Skor: 0.7592	Insecurity Skor: 0.9885	Father's Day Skor: 380.3549	Flying For The First Skor: 0.9985
3	Counting Stars Skor: 1227.8387	Jacob's Ladder Skor: 0.7268	Kingdom of Heaven Skor: 0.9875	Pedals Press the Flo Skor: 379.9410	Hobo Lullaby Skor: 0.9981
4	Streetlight in the E Skor: 1227.3507	Stories To Tell Skor: 0.7254	Psalm 86 Skor: 0.9873	Counting Stars Skor: 379.9367	Pedals Press the Flo Skor: 0.9980
5	Crockdile Rock Skor: 1226.6286	Master Maqui - Area Skor: 0.7234	I Can Only Imagine Skor: 0.9869	Flying For The First Skor: 379.5551	1 vs 7 Billion Skor: 0.9978
6	They Can't If You Do Skor: 1219.0009	"Ob-La-Di Skor: 0.7211	Coffee Break Skor: 0.9861	Crockdile Rock Skor: 379.5521	Amen Skor: 0.9973
7	40 Miler Skor: 1216.1699	今、君に会いに行く Skor: 0.7189	So Long Skor: 0.9860	Burn the House Down Skor: 379.5473	Every Mother's Son Skor: 0.9972
8	Times Are Not Changi Skor: 1215.3512	On Freedom (A Carol) Skor: 0.7185	Wayfaring Stranger Skor: 0.9857	They Can't If You Do Skor: 379.1537	Pinocchio's Demise Skor: 0.9968
9	Pedals Press the Flo Skor: 1214.8742	"And Still Skor: 0.7037	Goodbye Skor: 0.9853	God Gave Me You Skor: 379.1460	Make It Through Skor: 0.9964
10	Flying For The First Skor: 1212.0655	"Doctor Skor: 0.7027	Father's Day Skor: 0.9851	Healing Touch Skor: 378.7532	God Gave Me You Skor: 0.9963
11	Healing Touch Skor: 1211.2394	"Poems Skor: 0.7018	What Have I Done? Skor: 0.9851	Amen Skor: 378.7446	They Can't If You Do Skor: 0.9960
12	God Gave Me You Skor: 1210.6322	T.W.L [YZ ver.] Skor: 0.6988	Flying For The First Skor: 0.9850	Lights Explode Skor: 378.7433	Hang On Skor: 0.9956
13	Amen Skor: 1206.9531	"One more time Skor: 0.6980	Policy Man Skor: 0.9849	Times Are Not Changi Skor: 378.7430	Not Over You Skor: 0.9954
14	Lights Explode Skor: 1206.3330	"Don't Think Twice Skor: 0.6918	Picture in a Frame Skor: 0.9847	40 Miler Skor: 378.3544	We Are Young - acous Skor: 0.9940
15	Look To The Side Skor: 1202.2098	"Of Peace Skor: 0.6915	Fire Skor: 0.9847	Hobo Lullaby Skor: 378.3456	Look To The Side Skor: 0.9936
16	Leave You Alone Skor: 1201.8555	"highway Skor: 0.6909	kiseki wa itsudemo - Skor: 0.9847	Look To The Side Skor: 377.9599	Sister Skor: 0.9930
17	Hobo Lullaby Skor: 1201.5717	Tamacun - Area 52 Ve Skor: 0.6909	Long Ride Home Skor: 0.9843	Rattle Snake Skor: 377.5554	I Feel The Same Skor: 0.9930
18	Rattle Snake Skor: 1200.3239	White Flag Skor: 0.6905	Tomorrow Is A Long T Skor: 0.9841	Every Mother's Son Skor: 377.5526	Lights Explode Skor: 0.9926
19	Every Mother's Son Skor: 1196.1782	Technicolor Skor: 0.6872	Send in the Clowns Skor: 0.9840	Not Over You Skor: 376.3609	The Sound of Silence Skor: 0.9926
20	Open Up Your Eyes Skor: 1193.4102	"Jesus Skor: 0.6810	Go Insane (feat. Ron Skor: 0.9839	Make It Through Skor: 376.3536	Out Loud Skor: 0.9925

500 düşümde model davranışları stabilize olmuş ve algoritmalar büyük ölçüde benzer öneriler üretmiştir

4.4.3 Büyük Ölçekli Örneklemeler (1000 – 5000)

Base 1000 - Karşılaştırma Tablosu

Sıra	Malatya	K-Means	KNN	Random Forest	Naive Bayes
1	Together As One (fea 20120.00	Sunday Best - Live a 20120.00	Kingpin 9.78	Together As One (fea 5030.00	Piloto de Fuga - Leo 8.77
2	Baby 793.81	Luta 20120.00	2012 - Feat. The Par 9.76	Baby 395.70	Agita (feat. El Mich 8.28
3	I'm Down (feat. Dee- 91.81	Lights 20120.00	Dilo Como Yo (Te Est 9.73	I'm Down (feat. Dee- 44.45	2012 - Feat. The Par 7.99
4	Everybody Talks 86.24	E Go Listen (feat. J 9.41	Jericho 9.73	Everybody Talks 40.81	E Go Listen (feat. J 7.95
5	Immigrant Visa 82.29	Piloto de Fuga 9.34	March of the Idiots 9.73	Immigrant Visa 39.32	Yo Momma 7.85
6	Bless the Lord 78.42	Thank You Lord (feat 9.28	Lazy Bones Harold Bu 9.73	Bless the Lord 37.60	Human Disco Ball 7.84
7	In The End 77.39	Piloto de Fuga - Leo 9.24	La Bostelle 9.72	Courtesy Call 37.09	Tempos Insanos 7.74
8	Courtesy Call 77.38	Dancing Groove Featu 9.19	生きてる生きてく 9.71	Rosemary 37.03	Maga Traz a Lenha - 7.74
9	Rosemary 77.13	Darker Shade of Blac 9.09	Stella and Sam Theme 9.71	No Te Apartes de Mi 36.37	Maga Traz a Lenha 7.64
10	War of Change 75.87	Darker Shade of Pale 9.03	Yan-Nah Mama-Loo 9.70	In The End 36.35	El Pacino 7.60
11	No Te Apartes de Mi 75.49	Agita (feat. El Mich 9.01	J.B R.I.P 9.70	War of Change 35.72	Tempos Insanos - Fri 7.55
12	Lo malo de ser bueno 74.51	The Penetrator 9.00	Not There Yet 9.68	Lo malo de ser bueno 35.13	Fatty Boom Boom 7.54
13	Absolute Zero 73.88	2012 - Feat. The Par 8.98	辞世の句 9.68	I Won't Give Up 34.76	Tempos Insanos - Cop 7.48
14	No Me Importa el Din 72.62	Tempos Insanos - Cop 8.96	Soldier Boy 9.68	Absolute Zero 34.47	Mugabe 7.46
15	Take a Walk 72.55	Felicia 8.95	Juliana 9.68	No Me Importa el Din 34.41	Thank You Lord (feat 7.42
16	Entombed 72.53	Legalise It 8.91	Best Days of Our Liv 9.67	Take a Walk 34.39	Rapinbolada 7.39
17	Another Way Out 72.46	No Balanco de Canoa 8.87	Point of No Return 9.67	Entombed 34.38	Movin 7.36
18	Enamorado tuyo 72.26	Fatty Boom Boom 8.86	Jumbo 9.67	Enamorado tuyo 34.06	Tá Amarrado 7.35
19	A Little Death 71.63	Tá Amarrado 8.81	Assomdwee 9.67	A Little Death 33.91	J.B R.I.P 7.33
20	Me Estoy Enamorando 71.27	Cyber Space Jam 8.73	Time for Me 9.67	Another Way Out 33.87	Rapinbolada - Dr. Da 7.23

1000 düğümlü büyük ölçekli örneklemde algoritmaların önerileri büyük ölçüde örtüşmektedir. Özellikle Random Forest, KNN ve Naive Bayes modellerinin üst sıralarda benzer şarkıları önermesi, veri setinin artık yeterli temsil gücüne ulaştığını ve model çıktılarının stabilize olduğunu göstermektedir. Bu aşamada algoritmalar arasındaki farklar belirgin ölçüde azalmıştır.

Base 2000 - Karşılaştırma Tablosu

Sıra	Malatya	K-Means	KNN	Random Forest	Naive Bayes
1	Together As One (fea 20120.00	Sunday Best - Live a 20120.00	Lovergirls Precinct 9.79	Together As One (fea 5030.00	Piloto de Fuga - Leo 8.77
2	Baby 793.81	Luta 20120.00	Kingpin 9.78	Baby 395.70	Agita (feat. El Mich 8.28
3	Miserere 260.00	Lights 20120.00	2012 - Feat. The Par 9.76	Miserere 65.00	2012 - Feat. The Par 7.99
4	I'm Down (feat. Dee- 91.81	Fall 20120.00	Dilo Como Yo (Te Est 9.73	I'm Down (feat. Dee- 44.45	E Go Listen (feat. J 7.95
5	Everybody Talks 86.24	Quizás 20120.00	Jericho 9.73	Everybody Talks 40.81	Yo Momma 7.85
6	Immigrant Visa 82.29	Ja 20120.00	March of the Idiots 9.73	Immigrant Visa 39.32	Human Disco Ball 7.84
7	Bless the Lord 78.42	It's Dark 20120.00	Lazy Bones Harold Bu 9.73	Bless the Lord 37.60	Tempos Insanos 7.74
8	In The End 77.39	Sonata For Solo Cell 20120.00	Te He Prometido 9.73	Courtesy Call 37.09	Maga Traz a Lenha - 7.74
9	Courtesy Call 77.38	I Dreamed of Choirs 20120.00	La Bostelle 9.72	Rosemary 37.03	Sabor a Mi 7.67
10	Rosemary 77.13	Living Lips 9.45	生きてる生きてく 9.71	No Te Apartes de Mi 36.37	Maga Traz a Lenha 7.64
11	A las Nueve 76.04	E Go Listen (feat. J 9.41	Stella and Sam Theme 9.71	In The End 36.35	El Pacino 7.60
12	War of Change 75.87	Piloto de Fuga 9.34	Yan-Nah Mama-Loo 9.70	A las Nueve 36.01	Keep Keep 7.56
13	No Te Apartes de Mi 75.49	Lostfound 9.34	J.B R.I.P 9.70	War of Change 35.72	Tempos Insanos - Fri 7.55
14	Lo malo de ser bueno 74.51	Thank You Lord (feat 9.28	Not There Yet 9.68	Lo malo de ser bueno 35.13	Fatty Boom Boom 7.54
15	Absolute Zero 73.88	Piloto de Fuga - Leo 9.24	辞世の句 9.68	Turning Page 34.93	Tempos Insanos - Cop 7.48
16	No Me Importa el Din 72.62	Dancing Groove Featu 9.19	Soldier Boy 9.68	I Won't Give Up 34.76	Mugabe 7.46
17	Take a Walk 72.55	Darker Shade of Blac 9.09	Juliana 9.68	Ese Maldito Momento 34.54	Thank You Lord (feat 7.42
18	Entombed 72.53	Darker Shade of Pale 9.03	Best Days of Our Liv 9.67	Absolute Zero 34.47	Rapinbolada 7.39
19	Another Way Out 72.46	Agita (feat. El Mich 9.01	Point of No Return 9.67	No Me Importa el Din 34.41	Movin 7.36
20	Enamorado tuyo 72.26	The Penetrator 9.00	Jumbo 9.67	Take a Walk 34.39	Vision Of Love 7.36

2000 düğümlü örneklemede algoritmaların önerileri büyük ölçüde örtüşmekte ve model çıktıları belirgin biçimde stabilize olmaktadır. Random Forest, KNN ve Naive Bayes modellerinin üst sıralarda benzer şarkıları önermesi, veri setinin popülerlik örüntülerini yeterli düzeyde temsil ettiğini göstermektedir. Bu aşamada algoritma seçiminden kaynaklanan farklar oldukça sınırlı hâle gelmiştir.

Base 5000 - Karşılaştırma Tablosu

Sıra	Malatya	K-Means	KNN	Random Forest	Naive Bayes
1	Together As One (fea 20120.00	Sunday Best - Live a 20120.00	5 10.00	Together As One (fea 5030.00	Don Giovanni 724320.00
2	Don Giovanni 20120.00	Luta 20120.00	Thundercats 10.00	Don Giovanni 5030.00	All-night Vigil 643840.00
3	All-night Vigil 20120.00	Lights 20120.00	Taaveti laul 104 10.00	All-night Vigil 5030.00	All-night Vigil 523120.00
4	12 Trio Sonatas 20120.00	Fall 20120.00	All-night Vigil 9.95	12 Trio Sonatas 5030.00	12 Trio Sonatas 482880.00
5	All-night Vigil 20120.00	Quizás 20120.00	All-night Vigil 9.94	All-night Vigil 5030.00	Taaveti laul 141 482880.00
6	Octet in E Flat Majo 20120.00	Ja 20120.00	Komm 9.94	Octet in E Flat Majo 5030.00	Komm 462760.00
7	Taaveti laul 141 20120.00	It's Dark 20120.00	Taaveti laul 141 9.90	Taaveti laul 141 5030.00	Bach - 3 chorales 402400.00
8	Don Giovanni 20120.00	Sonata For Solo Cell 20120.00	All-night Vigil 9.90	Don Giovanni 5030.00	Harold en Italie 382280.00
9	Komm 20120.00	I Dreamed of Choirs 20120.00	Star Runner 9.84	Komm 5030.00	Octet in E Flat Majo 342040.00
10	All-night Vigil 20120.00	Night Woven of Snow 20120.00	P.L. High Theme 9.83	All-night Vigil 5030.00	All-night Vigil 342040.00
11	Don Giovanni 20120.00	Goodnight 20120.00	錆びついた夜 9.82	Don Giovanni 5030.00	Don Giovanni 321920.00
12	Harold en Italie 20120.00	I Don't Wanna Lose 20120.00	Bach - 3 chorales 9.80	Harold en Italie 5030.00	Concerto for Harpsic 301800.00
13	Bach - 3 chorales 20120.00	Strobe Lights 20120.00	Lovergirls Precinct 9.79	Bach - 3 chorales 5030.00	Don Giovanni 241440.00
14	Dornröschen 20120.00	Strobe Lights 20120.00	Twinkle (Little Chri 9.79	Dornröschen 5030.00	Dornröschen 221320.00
15	Concerto for Harpsic 20120.00	Etudes symphoniques 20120.00	Kingpin 9.78	Concerto for Harpsic 5030.00	Nocturne in C-Sharp 10500.00
16	Baby 793.81	Bach - 3 chorales 20120.00	Always Something 9.78	Baby 395.70	Lohengrin: Act III S 580.00
17	Symphony No. 88 in G 526.78	Das Wohltemperierte 20120.00	Zones Without People 9.77	Symphony No. 88 in G 261.94	Bach 570.00
18	Stills & Nash 463.68	Bach 20120.00	2012 - Feat. The Par 9.76	Stills & Nash 230.92	Don Giovanni 500.00
19	River Deep 391.17	Nocturne in E-Flat M 20120.00	午夜皇后 9.76	River Deep 194.79	Piloto de Fuga - Leo 8.77
20	Lohengrin: Act III S 290.00	2 Pieces 20120.00	Dance Face 2000 9.76	Concerto for Recorde 134.39	2 Turntables and a C 8.60

5000 düğümlü en büyük örneklemede algoritmaların önerileri neredeyse tamamen örtüşmektedir. Random Forest, KNN ve Naive Bayes modellerinin üst sıralarda aynı veya çok benzer şarkıları önermesi, veri setinin popülerlik örüntülerini tam anlamıyla temsil ettiğini göstermektedir. Bu aşamada algoritmalar arasındaki farklar ihmal edilebilir düzeye inmiş ve model çıktıları doygunluk seviyesine ulaşmıştır.

5. Sonuçlar ve Tartışma

Bu çalışmada, Spotify veri kümesindeki akustik özellikler kullanılarak şarkı popülerliğinin tahmini gerçekleştirilmiş ve beş farklı yaklaşım (Malatya Centrality, K-Means, KNN, Random Forest ve Naive Bayes) çoklu veri senaryolarında karşılaştırılmıştır. Elde edilen deneysel bulgular, veri miktarı arttıkça modellerin davranışlarının belirgin biçimde değiştiğini göstermektedir.

Sınıflandırma sonuçları değerlendirildiğinde, Random Forest modeli hem doğruluk hem de F1 skoru açısından en kararlı ve yüksek başarıyı üretmiştir. Küçük örneklem setlerinde dalgalanmalar görülse de, veri büyüdükçe hatalar azalmakta ve model daha güvenilir hale gelmektedir. KNN, düşük veri miktarında istikrarsız olsa da yüksek veri hacminde dengelenmiş; Naive Bayes ise hızlı olmasına rağmen yüksek karmaşıklık karşısında performans kaybı yaşamıştır. Bu bulgu, popülerlik tahmininde ensemble temelli yaklaşımların daha avantajlı olduğunu ortaya koymaktadır.

Özellikle K-Means sonuçları, akustik özelliklerin doğal kümelenme eğilimi taşıdığını ve veri boyutu büyüdükçe kümeler arası ayrışmanın arttığını göstermiştir. Bu durum, Spotify içeriğinin yalnızca sınıflandırma değil, segmentasyon ve öneri sistemleri için de yapısal potansiyel sunduğunu kanıtlamaktadır.

Malatya Centrality analizleri, veri içindeki özelliklerin ilişkisel ağına odaklanarak farklı bir bakış açısı sağlamıştır. En yüksek merkezilik değerine sahip düğümlerin hem tahmin performansını hem de öneri tablolarındaki sıralamaları etkilediği tespit edilmiştir. PCA görselleştirmesi, bu düğümlerin rastlantısal değil, yoğunlaşmış bölgelerde toplandığını göstermiş; bu da MC'nin gelecekte özellik seçimi veya veri azaltma süreçlerinde kullanılabileceğini düşündürmektedir.

Tablolar üzerinden yapılan incelemeler, örneklem büyüdükçe modellerin önerdiği sonuçların birbirine yaklaştığını, özellikle 1000+ gözlem seviyesinde üç modelin (RF, NB, KNN) benzer parçalarda buluştuğunu göstermiştir. Bu durum, model davranışının veri hacmi ile stabilize olduğunu, küçük örneklemelerde ise rastlantısallığın etkili olduğunu ortaya koymaktadır.

Genel olarak, çalışma üç temel sonucu desteklemektedir:

1. Doğruluk odaklı tahminlerde Random Forest en uygun yaklaşımdır.
2. Hız ve maliyet odaklı senaryolarda Naive Bayes kullanılabilir.
3. Büyük veri setlerinde özellik merkeziliği analizi (MC), yapısal avantaj sağlar.

6. Proje Kodları ve Uygulama Detayları

Bu bölümde, çalışmada geliştirilen yazılımın kaynak kodları sunulmakta ve her bir modülün deneysel süreçteki rolü açıklanmaktadır. Kodlar, deneylerin tekrar edilebilirliğini sağlamak amacıyla modüler bir yapı ile geliştirilmiştir.

6.1 Veri Yükleme ve Ön İşleme Kodu (loader.py)

Bu dosya, Spotify veri setinin sisteme yüklenmesi, yalnızca sayısal özelliklerin seçilmesi ve eksik/sorunlu değerlerin temizlenmesinden sorumludur.

```
import pandas as pd
import numpy as np

def load_spotify_data(file_path):
    df = pd.read_csv(file_path)
```

```

numeric_columns = [
    'popularity', 'year', 'danceability', 'energy', 'key',
    'loudness', 'mode', 'speechiness', 'acousticness',
    'instrumentalness', 'liveness', 'valence', 'tempo',
    'duration_ms', 'time_signature'
]

df = df[numeric_columns]

df = df.replace([np.inf, -np.inf], np.nan)
df = df.fillna(df.mean())

return df.reset_index(drop=True)

```

Bu kod parçası, raporun **3.2 Veri Seti ve Ön İşleme Adımları** bölümünde açıklanan Min-Max/ölçekleme öncesi veri temizleme sürecini yazılımsal olarak gerçekleştirmektedir.

6.2 Algoritma Skor Hesaplama Kodları (algorithms.py)

Bu dosyada her algoritma için ayrı bir skor hesaplama fonksiyonu tanımlanmıştır.

6.2.1 Malatya Centrality Algoritması

```

def malatya_centrality(df, base_nodes, new_node):
    base_features = df.iloc[base_nodes].values
    new_features = df.iloc[new_node].values.reshape(1, -1)

    scaler = StandardScaler()
    base_scaled = scaler.fit_transform(base_features)
    new_scaled = scaler.transform(new_features)

    distances = np.sqrt(np.sum((base_scaled - new_scaled) ** 2, axis=1))
    score = np.sum(1 / (1 + distances))

    return float(score)

```

Bu algoritma, yeni düğümün base düğümlere olan mesafelerine dayalı bir merkezilik skoru üretmektedir.

6.2.2 K-Means Skor Hesaplama

```

def kmeans_score(df, base_nodes, new_node):
    base_features = df.iloc[base_nodes].values
    new_features = df.iloc[new_node].values.reshape(1, -1)

    scaler = StandardScaler()

```

```

base_scaled = scaler.fit_transform(base_features)
new_scaled = scaler.transform(new_features)

kmeans = KMeans(n_clusters=3, random_state=42)
kmeans.fit(base_scaled)

distances = np.linalg.norm(kmeans.cluster_centers_ - new_scaled, axis=1)
return float(1 / (1 + distances.min()))

```

6.2.3 KNN Skor Hesaplama

```

def knn_score(df, base_nodes, new_node):
    base_features = df.iloc[base_nodes].values
    new_features = df.iloc[new_node].values.reshape(1, -1)

    scaler = StandardScaler()
    base_scaled = scaler.fit_transform(base_features)
    new_scaled = scaler.transform(new_features)

    knn = NearestNeighbors(n_neighbors=5)
    knn.fit(base_scaled)

    distances, _ = knn.kneighbors(new_scaled)
    return float(1 / (1 + distances.mean()))

```

6.2.4 Random Forest Skor Hesaplama

```

def random_forest_score(df, base_nodes, new_node):
    X = df.iloc[base_nodes].values
    y = df.iloc[base_nodes]['popularity'].values

    scaler = StandardScaler()
    X_scaled = scaler.fit_transform(X)
    new_scaled = scaler.transform(df.iloc[new_node].values.reshape(1, -1))

    rf = RandomForestRegressor(n_estimators=50, random_state=42)
    rf.fit(X_scaled, y)

    return float(rf.predict(new_scaled)[0])

```

6.2.5 Naive Bayes Skor Hesaplama

```

def naive_bayes_score(df, base_nodes, new_node):
    X = df.iloc[base_nodes].values
    y = (df.iloc[base_nodes]['popularity'] > 50).astype(int)

    scaler = StandardScaler()

```

```
X_scaled = scaler.fit_transform(X)
new_scaled = scaler.transform(df.iloc[new_node].values.reshape(1, -1))

nb = GaussianNB()
nb.fit(X_scaled, y)

return float(nb.predict_proba(new_scaled).max())
```

6.3 Deneylerin Yürütülmesi (experiments.py)

Bu dosya, farklı base boyutları ve algoritmalar için deneylerin otomatik olarak çalıştırılmasını sağlar.

```
def run_experiment(df, base_size, algorithm):
    base_nodes = np.random.choice(len(df), base_size, replace=False)
    remaining_nodes = [i for i in range(len(df)) if i not in base_nodes]

    results = []
    for node in remaining_nodes[:base_size]:
        score = algorithm(df, base_nodes, node)
        results.append((node, score))

    return sorted(results, key=lambda x: x[1], reverse=True)
```

Bu yapı, raporda sunulan tüm karşılaştırma tablolarının temelini oluşturmaktadır.

6.4 Ana Çalıştırma Dosyası (main.py)

```
def main():
    df = load_spotify_data("spotify_data.csv")
    base_sizes = [10, 20, 50, 100, 200, 500, 1000, 2000, 5000]

    for base in base_sizes:
        results = run_experiment(df, base, malatya centrality)
        print(f"Base {base} sonuçları:", results[:5])
```

Bu dosya çalıştırıldığında, tüm deneysel süreç otomatik olarak başlatılmaktadır.

6.5 Kodların Akademik Katkısı

Bu bölümde sunulan kaynak kodlar sayesinde gerçekleştirilen tüm deneyler birebir şekilde tekrar edilebilir hâle getirilmiştir. Kullanılan algoritmalar aynı veri seti ve aynı deneysel koşullar altında çalıştırılarak adil ve tutarlı bir karşılaştırma ortamı sağlanmıştır. Ayrıca raporun önceki bölümlerinde teorik olarak açıklanan yöntemler, yazılımsal uygulamalar ile desteklenmiş ve elde edilen sonuçların somut bir temele dayandığı gösterilmiştir. Bu yönüyle

alıřma, yalnızca elde edilen ıktılara odaklanan bir analiz olmanın ötesine geerek, uygulanabilir ve geliřtirilebilir bir veri madencilięi projesi nitelięi tařımaktadır.

7. EKLER

Bu bölümde, alıřmada kullanılan yöntemlerin teorik altyapısını destekleyen ve literatürde Spotify veri seti üzerinde gerekleřtirilen benzer alıřmaları ieren bilimsel yayınlar sunulmaktadır. Ekler kapsamında yer alan bu kaynaklar; řarkı popölerlięi tahmini, müzik öneri sistemleri, makine öğrenmesi ve derin öğrenme yaklařımlarının Spotify verileri üzerindeki uygulamalarını kapsamaktadır. alıřmanın yöntemsel tercihleri ve elde edilen bulgular, bu literatür doęrultusunda řekillendirilmiř ve karřılařtırmalı olarak deęerlendirilmiřtir.

EK-1: Kaynaklar

1. Saragih, R. (2023). *Predicting Song Popularity Based on Spotify's Audio Features*. Taylor & Francis.
2. Luo, J. (2018). *Machine Learning Approach for Genre Prediction on Spotify Top Ranking Songs*. University of North Carolina.
3. Maheshwari, C., et al. (2023). *Music Recommendation on Spotify Using Deep Learning*. arXiv:2312.10079.
4. Middlebrook, A., & Sheik, S. (2019). *Song Hit Prediction: Predicting Billboard Hits Using Spotify Data*. arXiv.
5. Kambham, S. (2025). *Emotion Detection and Music Recommendation System*. arXiv.
6. Janardhan, S., & Plavchan, C. (2023). *Clustering with K-Means to Classify Spotify Songs*. George Mason University.
7. Mountzouris, D. (2025). *Predicting Billboard Hot 100 Chart Inclusion with Machine Learning*. arXiv.
8. ABAcademies. (2025). *Decoding Spotify Hits: Statistical and Predictive Analysis of Track Features Driving Song Popularity*.
9. (2024). *Predicting Music Popularity: A Machine Learning Approach Using Spotify Data*. SciTePress.
10. (2024). *Analysis of Machine Learning-Based Music Recommendation System Using Spotify Datasets*. ResearchGate.
11. (2023). *Spotify Song Analysis by Statistical Machine Learning*. Unibo CRIS.
12. (2024). *Music Recommendation System on Spotify Using Deep Learning*. ResearchGate.
13. (2023). *User Based Spotify Recommendation System Using Machine Learning Algorithms*. International Journal of Innovative Science and Research Technology.
14. Wittenbrink, B. (2023). *Spotify Track Neural Recommender System*. Medium (Stanford CS224W: Machine Learning with Graphs).
15. Dieleman, S. (2014). *Recommending Music on Spotify with Deep Learning*. Blog Yazısı / Makale.
16. (2022). *Machine Learning System Implementation of Education Podcast Recommendations on Spotify Applications Using Content-Based Filtering*. Journal UNY.
17. (2024). *How Spotify Uses Machine Learning?* ProjectPro.

18. Maheshwari, C. (2023). *Music Recommendation on Spotify Using Deep Learning*.
arXiv:2312.10079.